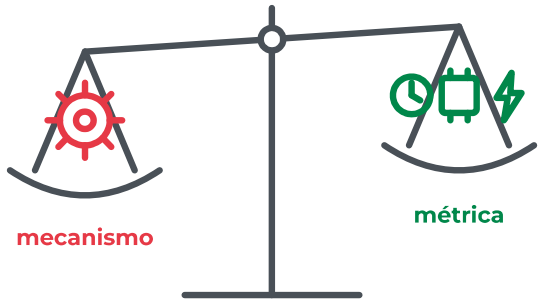
Faculdade de
Computação e Informática



Sistemas Operacionais - Projeto 2

Custo: quanto custa cada mecanismo

Prof. Lucas Figueiredo

Projeto 2

Ficha 1

lucascerfig.github.io/aulas/sistemas-operacionais/proj2-ficha1/

Entre com RA, nome e o seu código pessoal. Pelo RA você recupera a ficha em qualquer aparelho

Uma pessoa cria o grupo e passa o código para os demais

Os blocos da ficha vão abrindo conforme a aula chega neles

Cada bloco pode ser enviado quantas vezes quiser. Vale o último envio

Há partes individuais e partes em grupo. O primeiro momento é um brainstorm

escolha a turma

Estudo de Caso

O custo de rodar uma IA no Kindle

O aparelho

Kindle Paperwhite 4 (2018): processador ARM de um núcleo, 512 MB de RAM, Linux embarcado. Um leitor de livros, com terminal aberto por dentro.

Memória que sobra

O sistema do Kindle, a interface de leitura e o terminal ocupam a maior parte dos 512 MB. Para um programa novo sobram cerca de **161 MB**. Esse número é a parede de tudo que vem depois.

Modelos suportados

Modelos de linguagem pequenos, de 15 a 135 milhões de parâmetros, com os pesos lidos do cartão por mmap. Variam no tamanho, no tipo de dado dos pesos (float32, int8, 4 bits) e no tamanho do contexto.

A hipótese

Quanto custa o **tipo de dado** dos pesos (float32, int8, 4 bits) e quanto custa o **contexto** (a memória reservada para a conversa), lidos em memória ocupada e em velocidade de geração.

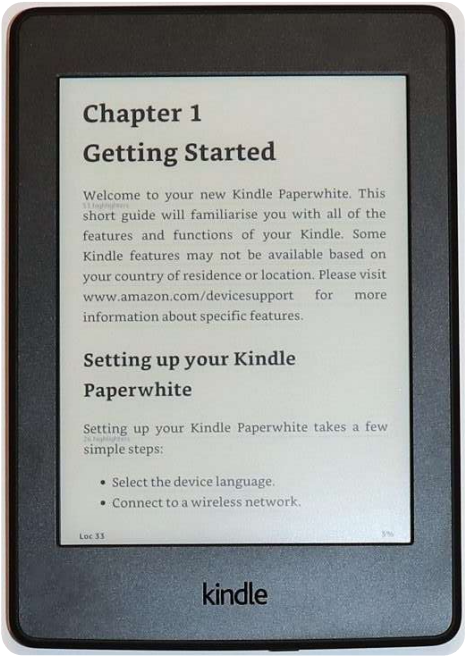
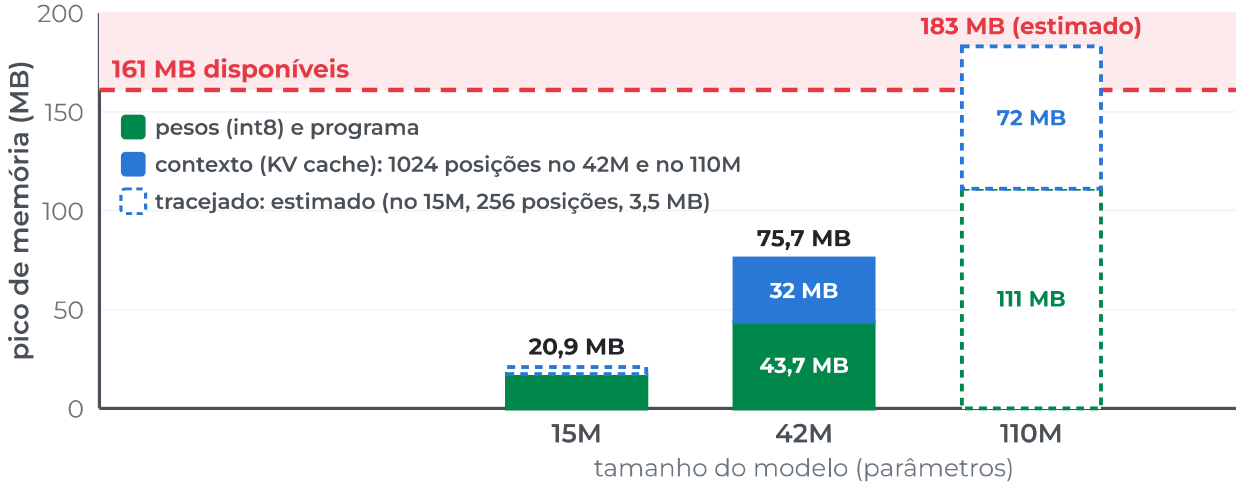


Foto: Wandelopa, Wikimedia Commons, CC BY-SA 4.0

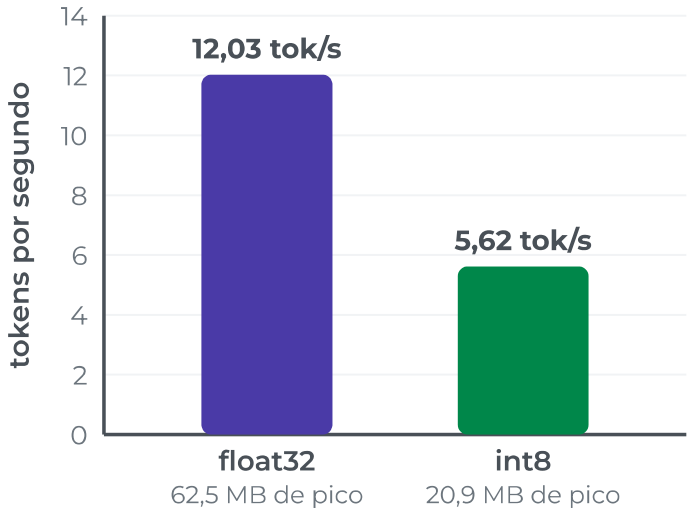
Estudo de Caso

As medições

Pico de memória por tamanho do modelo (int8): pesos e contexto



Velocidade por tipo de dado dos pesos (modelo de 15M)



Quantizar para int8 cortou a memória do 15M a um terço, e a velocidade caiu pela metade: a versão em int8 faz contas extras a cada camada e aproveita menos o processador.

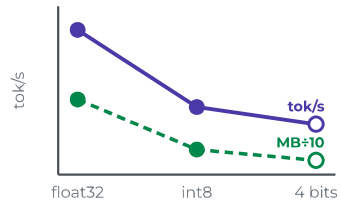
O contexto é pago adiantado: a memória reservada para 1024 posições da conversa (o KV cache) custa 32 MB no 42M mesmo quando a resposta usa 128.

O 110M não cabe por causa desse contexto: 111 MB de pesos e 72 MB de KV cache passam dos 161 MB.

Dividindo o Trabalho

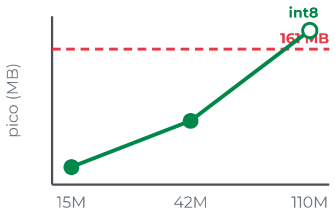
Cinco frentes de investigação no Kindle

Tipo de dado dos pesos, modelo fixo



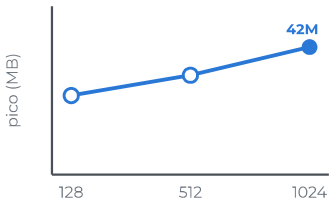
x: float32, int8, 4 bits · **y:** tok/s e MB
troca velocidade por memória

Tamanho do modelo, tipo de dado fixo



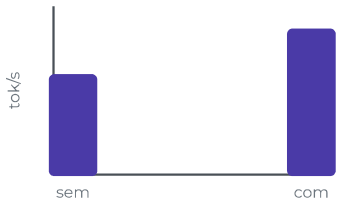
x: 15M, 42M, 110M · **y:** pico (MB)
onde deixa de caber

Tamanho do contexto



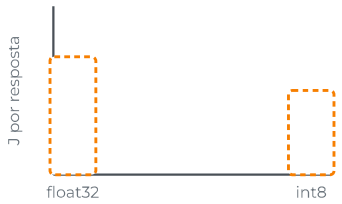
x: 128, 512, 1024 posições · **y:** pico (MB)
isola o custo do KV cache

Opções de compilação



x: sem e com instruções vetoriais · **y:** tok/s
46% sem gastar um byte

Bateria



x: float32, int8 · **y:** energia por resposta
ainda a medir: hipótese aberta

A pergunta do grupo é uma; cada integrante é dono de uma frente, com a sua variável, e defende a sua na apresentação.

Projeto 2

Critérios de avaliação

% 10% da nota

Acompanhamento pelo envio das fichas por grupo, uma por semana de laboratório, e pela apresentação em **25/11**.

Dispositivo e linguagem livres

Qualquer máquina com sistema operacional: notebook, celular, Raspberry, Kindle, Codespaces. O que importa é a pergunta ter uma variável.

Uma frente de investigação por integrante

Grupo de n entrega n frentes e n falam na apresentação. Cada integrante defende a sua.

Prova no tema do grupo

O pilar do OSTEP que o grupo escolher é o contexto cobrado dos integrantes na prova.

Duas entregas perdidas zeram o projeto

O grupo que deixar de fazer duas das entregas semanais recebe zero no projeto.

Dado gerado por IA zera o projeto

Nenhum dado pode ser gerado: todo dado é medido pelo grupo, no dispositivo do grupo. A visualização do custo pode ser feita com IA.

A Pergunta

Custo

quanto custa X, quando mudo Y, medido em Z

Slot	Kindle	Servidor de Minecraft
X mecanismo a parte do SO que tem preço	memória virtual: pesos por mmap e a reserva do contexto	concorrência: o tick de 50 ms é a seção crítica
Y variável mudada de propósito entre as medições	tipo de dado dos pesos e tamanho do modelo	número de jogadores simulados: 1 e 20
Z métrica em que se lê o custo, com unidade	tok/s e pico de memória (MB)	ms por tick, média e p99
hipótese	int8 cabe onde float32 não cabe, pagando em velocidade	o p99 estoura 50 ms antes da média

Partes do OSTEP

Pilares

Virtualização de CPU

troca de contexto
escalonamento
chamada de sistema
processos e threads

quanto custa cada thread a mais no tempo de um quadro de jogo

Virtualização de memória

falta de página
TLB
swap e pressão de memória
tipo de dado e tamanho em memória

quanto cresce o tempo por token quando o modelo deixa de caber na RAM

Concorrência

lock e contenção
variável de condição
deadlock
paralelismo real e aparente

quanto custa coordenar quando os clientes de um servidor crescem

Persistência

fsync e cache de escrita
journaling
sistema de arquivos
desgaste do armazenamento

quanto custa garantir que o dado chegou ao disco, e quanto custa não garantir

Segurança

isolamento e contêiner
permissões
cifragem

quanto custa cifrar o disco, em tempo e em energia

O grupo pergunta dentro de qualquer pilar. As três perguntas individuais do início podem estar em pilares diferentes.

Como Medir o Custo

Métricas

tempo
média e cauda (p99): ms por requisição, por tick, por token

espaço
memória residente (RSS), pico, espaço em disco

energia
joules ou Wh por tarefa; bateria gasta por hora

calor
temperatura do processador e queda de frequência (throttling)

desgaste
bytes escritos no cartão ou no SSD por hora de uso

dados perdidos
registros que sumiram depois de um kill -9 ou de um cabo puxado

dinheiro
core-hora ou custo por mil requisições na nuvem

variância
a mesma medida repetida: quanto ela oscila entre rodadas

A métrica escolhida é estudada e explicada pelo grupo no relatório

Hoje basta dizer o que gostariam de medir. Na ficha 2, semana que vem, a métrica vem definida: o que ela significa e como vai ser medida.

Ideias

Perguntas com "quanto" em vários temas

SERVIDOR WEB OU API
Quanto custa cada cliente a mais no tempo de resposta p99?

CELULAR
Quanto custa manter uma conexão aberta em segundo plano, em bateria por hora?

RASPBERRY OU SENSOR
Quanto custa gravar uma leitura por segundo, em desgaste do cartão e em energia?

CONTÊINER
Quanto custa rodar o mesmo programa dentro de um contêiner, em tempo por chamada de sistema?

LEITOR DE LIVROS
Quanto custa o tipo de dado dos pesos de um modelo de linguagem, em memória e em velocidade?

BANCO DE DADOS
Quanto custa garantir que cada registro chegou ao disco, em tempo e em registros perdidos quando o processo morre?

JOGO OU EMULADOR
Quanto custa cada thread a mais no tempo de um quadro, na média e no p99?

DISCO CIFRADO
Quanto custa cifrar o disco, em tempo de cópia e em uso de CPU?

COMPILAÇÃO
Quanto custa compilar um projeto com a memória limitada, em tempo e em faltas de página?

SERVIDOR DE MINECRAFT
Quanto custa cada jogador a mais, em ms por tick?

São só exemplos. O grupo pode partir de um deles, mas precisa refinar a pergunta e torná-la sua. Qualquer máquina com sistema operacional serve, e qualquer domínio.

Bloco B da Ficha

Critérios de uma pergunta candidata

Campo	Kindle	Servidor de Minecraft
Pergunta em uma linha, com "quanto"	Quanto custa o tipo de dado dos pesos, quando mudo de float32 para int8, medido em tok/s e pico de memória?	Quanto custa cada jogador a mais, medido em ms por tick?
Pilar do OSTEP pode marcar mais de um	Virtualização de memória	Concorrência
Conceito mais próximo campo aberto	tipo de dado e tamanho em memória	lock e contenção
O que varia a variável	tipo de dado dos pesos: float32, int8 e 4 bits, com o modelo fixo	número de jogadores simulados: 1 e 20
O que mede a métrica, hoje em palavras	velocidade de geração e pico de memória do processo	tempo de cada tick, na média e no pior caso

Na ficha 2 a métrica vem com unidade e forma de medição. Hoje, o que o grupo gostaria de medir.

Formação

Grupos e códigos

1. Uma pessoa cria o grupo na ficha com um nome. O nome é público e não muda depois.
2. A ficha gera o código a partir do nome; quem criou passa o código para os demais.
3. De três a cinco integrantes. Com cinco, a ficha recusa e pede outro código.
4. Grupos do Projeto 1 podem continuar. O nome do time no repositório é o mesmo da ficha.

Bloco A · Individual

Três perguntas com "quanto"

Brainstorm individual: três perguntas do que você gostaria de medir, em qualquer tema e em qualquer máquina

Cada pergunta começa com quanto e cabe numa linha

Podem estar em pilares diferentes

São o insumo do bloco seguinte, o brainstorm em grupo

Código para abrir A QNTO

Na tela: o painel ao lado mostra, ao vivo, quantos entraram e quantos enviaram.

Bloco B · Grupo

Três perguntas candidatas

O grupo conversa sobre as perguntas individuais e fecha três candidatas, cada uma com pergunta, pilar, conceito, o que varia e o que mede

Um registro só por grupo: antes de mexer, "recuperar envios do grupo"; vale a última versão enviada

A ordem de envio é a ordem das rodadas de votação

Código para abrir B 

Na tela: o painel ao lado lista os grupos na ordem de envio, com os avisos da pré-checagem e os "discordo".

Bloco C · Turma

Votação por rodada

Nenhuma rodada aberta.

Para cada candidata do grupo da vez, a turma dá notas de 1 a 5 em cinco itens: curiosidade, investigação necessária, clareza da variável, clareza da métrica e viabilidade em quatro semanas. O próprio grupo lê e ouve. O resultado fica fechado até a última rodada.

Bloco D · Grupo

A pergunta do grupo

A ficha do grupo mostra o resultado da votação das suas três candidatas

O grupo vê a média de cada item e a média geral das três candidatas e escolhe uma. Os cinco campos voltam preenchidos para ajustar com os votos na mão

Cada integrante escreve a própria frente de investigação: uma variação da pergunta do grupo, com a sua variável

A pergunta final passa pela revisão do professor até a próxima aula, que é a última chance de ajustá-la. Nesta semana o grupo confere se é viável medir e como dividir

Na tela: o painel ao lado mostra os grupos com pergunta final enviada e as frentes de cada um.

Fechamento

A pergunta de cada grupo

Conferir carrega a lista; projetar mostra só nome e pergunta, em letra grande.

Calendário

Entregas, turma 4N

Data	Entrega	Em sala	Até lá
28/10	**Ficha 1: a pergunta**	brainstorm, candidatas, votação e escolha	dispositivo escolhido e repositório aceito, com o nome do grupo
04/11	**Ficha 2: método**	condições, hipótese, métrica definida; primeira medição com a tabela preenchida na hora	ler sobre a métrica escolhida; checar que a medição funciona no dispositivo
11/11	**Ficha 3: avaliação cruzada**	cada grupo avalia os dados de outro e pergunta; o avaliado responde	medições completas das frentes
18/11	**Ficha 4: storyboard**	uma afirmação, um gráfico, um limite; ensaio cronometrado	visualização do custo pronta
25/11	**Apresentação**	cada integrante defende a sua frente, relatório aberto	relatório no repositório

Entregáveis

Relatório
curto, até 10 páginas, em PDF: pergunta, método, resultados, discussão, limites, frentes por integrante, referências e declaração de uso de IA

Visualização do custo
com os dados medidos pelo grupo; pode ser feita com IA

Apresentação
uma frente por integrante, com o relatório aberto

Repositório
dados brutos e scripts; serve ao acompanhamento semanal e não é avaliado

Estrutura, diagramas e artefatos interativos construídos com apoio do modelo Claude Fable 5.1 (Anthropic); pré-checagem automática das candidatas da ficha pelo modelo Jev (TypeSafe, jev-1.14). Produção de conteúdo, sequência didática, verificação dos códigos e revisão final: Prof. Lucas Figueiredo.